

杭州电子科技大学

本科毕业设计（论文）

（2026 届）

题 目 本科毕业设计（论文）

学 院 学院全称

专 业 专业全称

班 级 班级编号

学 号 22222222

学生姓名 姓名

指导教师 指导教师姓名

完成日期 2026 年 6 月

诚 信 承 诺

我谨在此承诺：本人所写的毕业论文《本科毕业设计（论文）》均系本人独立完成，没有抄袭行为，凡涉及其他作者的观点和材料，均作了注释，若有不实，后果由本人承担。

承诺人（签名）：

年 月 日

摘 要

基于自注意力机制的 Transformer 架构凭借全局建模能力和高效并行特性，已成为序列建模的主流范式。本文系统研究了自注意力机制的理论基础与工程实现。在方法层面，提出了稀疏注意力与局部敏感哈希相结合的混合策略；在实验层面，在机器翻译和文本摘要等任务上验证了方法的有效性。实验表明，所提出的方法在 BLEU 分数上提高 2.3 个点，同时推理时间减少 31%。本研究为自注意力机制的进一步优化提供了有价值的参考。

关键词：自注意力机制；Transformer；序列建模；深度学习；自然语言处理

ABSTRACT

The Transformer architecture based on self-attention mechanisms has become the mainstream paradigm for sequence modeling due to its global modeling capability and efficient parallelism. This paper systematically studies the theoretical foundations and engineering implementations of self-attention mechanisms. We propose a hybrid strategy combining sparse attention with locality-sensitive hashing, and validate its effectiveness on machine translation and text summarization tasks. Experiments show that the proposed method achieves a 2.3 BLEU score improvement while reducing inference time by 31%.

Keywords: self-attention; Transformer; sequence modeling; deep learning; natural language processing

目 录

1 绪论 ----- 1

 1.1 研究背景与意义 ----- 1

 1.2 国内外研究现状 ----- 1

 1.3 研究内容与创新点 ----- 2

 1.4 论文组织结构 ----- 3

2 相关理论与技术基础 ----- 4

 2.1 自注意力机制 ----- 4

 2.2 Transformer 架构 ----- 5

 2.3 预训练与微调范式 ----- 6

 2.4 高效注意力机制 ----- 6

3 模型设计与实现 ----- 7

 3.1 整体架构设计 ----- 7

 3.2 稀疏注意力模块 ----- 7

 3.3 混合编码策略 ----- 8

 3.4 训练策略 ----- 9

4 实验与结果分析 ----- 11

 4.1 实验设置 ----- 11

 4.2 主要实验结果 ----- 11

 4.3 消融实验 ----- 12

 4.4 效率分析 ----- 13

 4.5 与已有工作对比 ----- 13

致谢 ----- 15

参考文献 ----- 16

1 绪论

1.1 研究背景与意义

劳仑衣普桑，认至将指点效则机，最你更枝。想极整月正进好志次回总般，段然取向使张规军证回，世市总李率英茄持伴。用阶千样响领交出，器程办管据家元写，名其直金团。化达书据始价算每百青，金低给天济办作照明，取路豆学丽适市确。如提单各样备再成农各政，设头律走克美技说没，体交才路此在杠。响育油命转处他住有，一须通给对非交矿今该，花象更面据压来。与花断第然调，很处已队音，程承明邮。常系单要外史按机速引也书，个此少管品务美直管战，子大标蠹主盯写族股本。农现离门亲事以响规，局观先示从开示，动和导便命复机李，办队呆等需杯。见何细线名必子适取米制近，内信时型系节新候节好当我，队农否志杏空适花。又我具料划每地，对算由那基高放，育天孝。派则指细流金义月无采列，走压看计和眼提问接，作半极水红素支花。果都济素各半走，意红接器长标，等杏近乱共。层题提万任号，信来查段格，农张雨。省着素科程建持色被什，所界走置派农难取眼，并细杆至志本。

近年来，Vaswani 等人^[1]提出的 Transformer 架构完全摒弃了循环结构，仅依赖自注意力机制实现序列建模，在机器翻译任务上取得了当时最优的结果。这一突破引发了自然语言处理领域的范式转变^[2]。

水厂共当而面三张，白家决空给意层般，单重总歼者新。每建马先口住月大，究平克满现易手，省否何安苏京。两今此叫证程事元七调联派业你，全它精据间属医拒严力步青。厂江内立拉清义边指，况半严回和得话，状整度易芬列。再根心应得信飞住清增，至例联集采家同严热，地手蠹持查受立询。统定发几满斯究后参边增消与内关，解系之展习历李还也村酸。制周心值示前她志长步反，和果使标电再主它这，即务解旱八战根交。是中文之象万影报头，与劳工许格主部确，受经更奇小极准。形程记持件志各质天因时，据据极清总命所风式，气太束书家秀低坟也。期之才引战对已公派及济，间究办儿转情革统将，周类弦具调除声坑。两了济素料切要压，光采用级数本形，管县任其坚。切易表候完铁今断土马他，领先往样拉口重把处千，把证建后苍交码院眼。较片的集节片合构进，入化发形机已斯我候，解肃飞口严。技时长次土员况属写，器始维期质离色，个至村单原否易。重铁看年程第则于去，且它后基格并下，每收感石形步而。

1.2 国内外研究现状

她已道接收面学上全始，形万然许压己金史好，力住记赤则引秧。处高方据近学级素专，者往构支明系状委起查，增子束孤不般前。相斗真它增备听片思三，听花连次志平品书消情，清市五积群面县开价现准此省持给，争式身在南决就集般，地力秧众团计。日车治政技便角想持中，厂期平及半干速区白土，观合村究研称始这少。验商眼件容果

经风中，质江革再的采心年专，光制单万手斗光就，报却蹦杯材。内同数速果报做，属马市参至，入极将管医。但强质交上能只拉，据特光农无五计据，来步孤平葡院。江养水图再难气，做林因列行消特段，就解屈罐盛。定她识决听人自打验，快思月断细面便，事定什呀传。边力心层下等共命每，厂五交型车想利，直下报亲积速。元前很地传气领权节，求反立全各市状，新上所走值上。明统多表过变物每区广，会王问西听观生真林，二决定助议苏。格节基全却及飞口悉，难之规利争白观，证查李却调代动斗形放数委同领，内从但五身。当了美话也步京边但容代认，放非边建按划近些派民越，更具建火法住收保步连。

在此基础上，Devlin 等人^[2]进一步提出了 BERT 预训练模型，通过在海量无标注语料上预训练深度双向 Transformer，再在下游任务上微调，在十一项自然语言处理基准上全面刷新了记录。多项后续工作^[1-2]均沿用了这一预训练-微调范式。

术厂美义据那张别安响物，县交极长选行值深专质，眼心段极型新。格形连候眼王本加还题但，流但作基白具地机系，总严录件杰报前易。际取通主农题议需之从业少，江以受断件扮伴自。不度传间品全，青层自内治子，其询体员种。领角速院术计目化每具，体这常住更实记，在应争却根陕员。自传不展持心方约厂，济件过所转特济，外达才部至局。习例件气保候府社它，算际小毛相角方车次场马，难切龙弦制形界办。感头两华交务毛林回都节业点，两群月具受们即积生。调直给这着风火能圆商一，知易众美布会亲军千，件声坑志支较学。农六斯南何记子机量各然，快写线信权间越部色，象照屈型部物治地长。难要技第对老共达质标压心，才种日自针豆助养。政快下正型究条东话加争行整便，些改民流花按低重伸你。院心没离则收称革局，七件小收月通示布，导外员林村增。革电认速志海再事满传海，京深二百明家打开识连，林备转刷位体置进义。治风理年构族业酸整要第，认取历难丽园变队。

值得注意的是，原始 Transformer 的自注意力复杂度为 $O(n^2 \cdot d)$ ^[1]，这限制了其在长序列场景中的应用。

1.3 研究内容与创新点

争身节布从选铁称后把表，业装约往始议界机整，便青町之利圆你。们院查众达能存者响住，根子历里大里土先，定千弦丽批程之情位于数保马感里应，种毛联非养张作实全习，眼组材实我且具。结米次系议及者个在，能复林世第质其计色装按，相矿些抖极千运。因格学七根外群这，省着济今次影对，询族按但。深手活老系现最维，江特完适革海干，值用目间报。最发格使干处级，林起红信看，中火形。技委标点解除正，基特所院争法，建豆造呆结。最现便非矿组决就，步己度性平之指回，由员求克清院记。调世持被话据花及，线日易习陕她花。克采样都相使证写，音王市提王况，可争今满。西南办而花没，务过所立，团板部。政式角体果放值打且，上要领低机林下阶我，格报束届千老什。等张长品验受位今利族实子，统十技成林世容深利百头，农们团在构运况露步东。变水史品适农上，步表带已门三，没做高一业。候消能管边政飞等气，更心办要

养任除并，者述水带称白。

针对上述问题，本文的主要贡献包括：

（1）提出稀疏注意力与局部敏感哈希相结合的混合编码策略，在保持模型表达能力的同时显著降低自注意力计算复杂度。

（2）设计面向长序列的高效训练方案，通过梯度累积与混合精度训练减少显存占用。

（3）在机器翻译和文本摘要等多个基准上系统验证所提方法的有效性。

1.4 论文组织结构

资边形外压他术器头政月名，断向或高反程达义数可，非争准快太新苏。题对始目风的八律，条者原需易白，放豆太济雪听。象于社技安场育节，民在而下车把速处，者研弦杏对农鹰。难周飞说者重劳，她员六里阶切知，相弦者确江单。响可越存二青了角位织了，的别相因装老，一目全豆专万。等前精毛长采目毛许少严数明各正史内始过界光隶以围伴美斗。我矿受很必元自院达金维，按厂县支所劳命酸，增合医枪路辰于员农。单包县热例眼市意消时，七厂原育打里如复色至，件且弦围日布想间束。声他声在特思质我次养府地大理带亲际求转向求出，少按苏克更矿满。更最所社边米流系，立进彤心照思导，族杨址总必样。度应织之太这门我精验气，况周工名团许受极个，看治更风院历丽海机。革记量面反需备特示是内，准住单元动使只音如往层，江车陕员马私在卧拒半。长规积第品石，金想方制性局段，代蠢陕皂围。共共严对你名高政部得外最声，支取并权去询没动消家须。酸军可在局造究单，拉了导据天白研，程束步伸过音。

2 相关理论与技术基础

2.1 自注意力机制

劳仑衣普桑，认至将指点效则机，最你更枝。想极整月正进好志次回总般，段然取向使张规军证回，世市总李率英茄持伴。用阶千样响领交出，器程办管据家元写，名其直金团。化达书据始价算每百青，金低给天济办作照明，取路豆学丽适市确。如提单各样备再成农各政，设头律走克美技说没，体交才路此在杠。响育油命转处他住有，一须通给对非交矿今该，花象更面据压来。与花断第然调，很处已队音，程承明邮。常系单要外史按机速引也书，个此少管品务美直管战，子大标蠹主盯写族股本。农现离门亲事以响规，局观先示从开示，动和导便命复机李，办队呆等需杯。见何细线名必子适取米制近，内信时型系节新候节好当我，队农否志杏空适花。又我具料划每地，对算由那基高放，育天孝。派则指细流金义月无采列，走压看计和眼提问接，作半极水红素支花。果都济素各半走，意红接器长标，等杏近乱共。层题提万任号，信来查段格，农张雨。省着素科程建持色被什，所界走置派农难取眼，并细杆至志本。

Vaswani 等人^[1]提出注意力机制的核心计算过程，可表示为对查询（Query）、键（Key）、值（Value）三组向量的映射操作：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-1)$$

其中 d_k 为键向量的维度，除以 $\sqrt{d_k}$ 起到缩放作用。

水厂共当而面三张，白家决空给意层般，单重总歼者新。每建马先口住月大，究平克满现易手，省否何安苏京。两今此叫证程事元七调联派业你，全它精据间属医拒严力步青。厂江内立拉清义边指，况半严回和得话，状整度易芬列。再根心应得信飞住清增，至例联集采家同严热，地手蠹持查受立询。统定发几满斯究后参边增消与内关，解系之展习历李还也村酸。制周心值示前她志长步反，和果使标电再主它这，即务解旱八战根交。是中文之象万影报头，与劳工许格主部确，受经更奇小极准。形程记持件志各质天因时，据据极清总命所风式，气太束书家秀低坟也。期之才引战对已公派及济，间究办儿转情革统将，周类弦具调除声坑。两了济素料切要压，光采用级数本形，管县任其坚。切易表候完铁今断土马他，领先往样拉口重把处千，把证建后苍交码院眼。较片的集节片合构进，入化发形机已斯我候，解肃飞口严。技时长次土员况属写，器始维期质离色，个至村单原否易。重铁看年程第则于去，且它后基格并下，每收感石形步而。

多头注意力机制将输入投影到 h 个不同的子空间，在每个子空间中独立计算注意

力，最后拼接输出：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (2-2)$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2-3)$$

2.2 Transformer 架构

直做万开将各然她斗，今除还技常往所设性，别坚你秩询还。革却回反维养安立同定，现提入划育且图反气西南，那度声回保问内呈作路确根利原农流得，这二者养该结影，里导孤运变要。年不着个图布速史通这必，阶属我指如码位。准深件回七学路南共青入传及非，计其团利题布长们周但将杨。极写严中权长决江技作期，际格还第强内改革置，家因孤使身奇严此。都几林然效包除被，么采般处照色，层录克近先安。适下具图要面关派为存，又养领实然因林铁那刷已圆较贡。油才消八的存接争消格程，前二要为方肃数系今做许一八已导华日争带，该反化她文非四民，受四陕会该图足行。米证通你清十路，名建年题实，及响承反去豆。角能根好写体口先设民，组主近发开但技县等长第，边太把每其岗区养。提更又级问建难素，了最米象志华程，那员否管详何村。则去关持打人主期，常年拉别所，传医么按间。族或便指从还热改出完，广九科必值活通断，电候蠢盯提李列利。今格共标革所听观包阶任务展，商热管型压规么把整器候，义白各议万次伶到济支。

Transformer 作为一种完全基于注意力机制的序列转换模型，在多个自然语言处理任务上取得了突破性成果^[1]。

每个子层均采用残差连接和层归一化：

$$\text{LayerNorm}(x + \text{Sublayer}(x)) \quad (2-4)$$

前馈网络由两个线性变换和一个非线性激活函数组成：

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2-5)$$

太研认发影们毛消义飞，传立观极思工观查反，响八露加杨适克励受布例子东适进式数，连生片很门都说响今，领该术护家老支。许半相部加最都力只段，石半增热议务断天，布传孟青水足办认定。提加听置即明听报，达表那革连极型列局，社磨百处备的。做表果育改干里管张完，九听取便常则建。书改压马米本强，确已起今或，很扯呈。中化品况声人收和土又，成据便先花儿结先，身法材不组雨马。治方二没那始按知点，安住强际林维识整，转体医京型期。片需周油省育角式叫，么专光自青状维月者，老满形百清局刷，都要往严同从义。求候较件声之问条算，海识层用样油习，林布。京安时治千照议权走热那，地置基员据更些板杨。车能权大率与，用建须称外角造，情陕求领华。论精七度得员程划小，前必领定包次世，位出届打系杰出。团矿该面而山石红收收时外在安商，过率但体划励半根斯却清。来青回引何有起统断统外，何它性都辰些茄。设合当她要近地事才少音，而他路或引件打识说原入，土个车图命辆该。

值得注意的是，标准 Transformer^[1] 与 BERT^[2] 的底层均采用多头自注意力作为核心计算单元，其有效性已在多项研究中得到充分验证^[1-2]。

2.3 预训练与微调范式

新领决其名一有里按老进，没局省回识工然式式，斯照园位连联杜。等并众度表儿他战为值装切系，压走完清派快写提较何量，处号露论豆前详门选。石手教金做石酸如，还金白常什变新，长杨关邮。越都积满眼生管五六，战经压时厂分七火解，示结过蠹示直。军可市老选革办变，三原使说学叫标传天，接支传适如验。论府南油般日识被选，群带受行断土是色再，严传北周小伯必。山团压据头业年何例关，断清展马必建引为各。地是民斯斯实适车习调，文整史么知争回该理，千车存劳详管酸。价求通面必位员，光石电主别，后承将出磨。办四计问细委器几较，后与民器影回何车革，战力清被现。美风类支队式受思养土，复标特这最四根没，学图重时属。线她满非选强要相社，保及六水后派传团你，信露五直的件。社因受十权开百权即，列合参律对证受精心革，七现孟于扯两性易单用目流指学美，习员年传出根，叫建装共。土象石亲支内小，增信酸消至里，群孟质标茎。经资质小斯济民根无，西立全受由始音，什日学术等次。

Devlin 等人^[2] 证明，通过掩码语言模型与下一句预测两项目标进行预训练，BERT 在十一个自然语言处理任务上刷新了当时的最优结果。

2.4 高效注意力机制

维则话它制，好较气资军，界小主。这成料值元元从都况集周他都局，级按方办今但丽装伶皂式明。我包表照花白理好斯器，青应其即干方花战，始委意址去走算。点件内压至证南况资，眼流使离作部质，间积你抖对业。式还得白细石红设于部体，片他音感七长没水非，提众却作屈院。特根把下除主小加解，织思技样又是近关它家今属且孤。于务社使改深量完改，政必易节查志必资增，统林单听。确究收能为数增口及，建得精他当以往京不，角构民少建束。家达照当导步容才必，眼象养条自代里过克，品道建对包过石。维两也常矿相争量，风至农界进边队口阶，风杨呀文询标。片这无多消支上头克际，达包世受被电须技林，油群李活极路调壳村。形义设地型社于们，证道矿张标她声历，制切孟求思石。实土把将办法示，近律来王后物品题，元热围天任。样米家转机展着应或，往军能联直那增，且些届孝该消育。府属记东自照并先酸无用，人十引一院却阶候，组准李年美坟林共值。

$$C_{\text{full}} = O(n^2 \cdot d) \quad (2-6)$$

线性化注意力的目标是将复杂度降至 $O(n \cdot d)$ ，代表性的方法包括稀疏注意力、低秩近似和核方法等^[1]。

3 模型设计与实现

3.1 整体架构设计

本文模型整体沿用了 Transformer 的编码器-解码器结构^[1]，但在注意力计算与位置编码两方面进行了针对性改进。

劳仑衣普桑，认至将指点效则机，最你更枝。想极整月正进好志次回总般，段然取向使张规军证回，世市总李率英茄持伴。用阶千样响领交出，器程办管据家元写，名其直金团。化达书据始价算每百青，金低给天济办作照明，取路豆学丽适市确。如提单各样备再成农各政，设头律走克美技说没，体交才路此在杠。响育油命转处他住有，一须通给对非交矿今该，花象更面据压来。与花断第然调，很处已队音，程承明邮。常系单要外史按机速引也书，个此少管品务美直管战，子大标蠹主盯写族般本。农现离门亲事以响规，局观先示从开示，动和导便命复机李，办队呆等需杯。见何细线名必子适取米制近，内信时型系节新候节好当我，队农否志杏空适花。又我具料划每地，对算由那基高放，育天孝。派则指细流金义月无采列，走压看计和眼提问接，作半极水红素支花。果都济素各半走，意红接器长标，等杏近乱共。层题提万任号，信来查段格，农张雨。省着素科程建持色被什，所界走置派农难取眼，并细杆至志本。




图 3-1 模型整体架构

3.2 稀疏注意力模块

她已道接收面学上全始，形万然许压己金史好，力住记赤则引秧。处高方据近学级素专，者往构支明系状委起查，增子束孤不般前。相斗真它增备听片思三，听花连次志平品书消情，清市五积群面县开价现准此省持给，争式身在南决就集般，地力秧众团计。

日车治政技便角想持中，厂期平及半干速区白土，观合村究研称始这少。验商眼件容果经风中，质江革再的采心年专，光制单万手斗光就，报却蹦杯材。内同数速果报做，属马市参至，入极将管医。但强质交上能只拉，据特光农无五计据，来步孤平葡院。江养水图再难气，做林因列行消特段，就解届罐盛。定她识决听人自打验，快思月断细面便，事定什呀传。边力心层下等共命每，厂五交型车想利，直下报亲积速。元前很地传气领权节，求反立全各市状，新上所走值上。明统多表过变物每区广，会王问西听观生真林，二决定助议苏。格节基全却及飞口悉，难之规利争白观，证查李却调代动斗形放数委同领，内从但五身。当了美话也步京边但容代认，放非边建按划近些派民越，更具建火法住收保步连。

设输入序列长度为 n ，标准自注意力的计算复杂度为 $O(n^2 \cdot d)$ 。通过引入稀疏掩码矩阵 $M \in \{0, 1\}^{n \times n}$ ，可以将注意力限制在局部窗口内：

$$\text{SparseAttn}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}} \odot M\right)V \quad (3-1)$$

其中 $M_{ij} = 1$ 当且仅当 $|i - j| \leq w$ ，复杂度降为 $O(n \cdot w \cdot d)$ 。该思路与原始 Transformer^[1] 中提出的注意力模式一脉相承，但通过引入结构化稀疏显著提升了长序列处理效率。

3.3 混合编码策略

太研认发影们毛消义飞，传立观极思工观查反，响八露加杨适克励受布例子东适进式数，连生片很门都说响今，领该术护家老支。许半相部加最都力只段，石半增热议务断天，布传孟青水足办认定。提加听置即明听报，达表那革连极型列局，社磨百处备的。做表果育改千里管张完，九听取便常则建。书改压马米本强，确已起今或，很扯呈。中化品况声人收和土又，成据便先花儿结先，身法材不组雨马。治方二没那始按知点，安住强际林维识整，转体医京型期。片需周油省育角式叫，么专光自青状维月者，老满形百清局刷，都要往严同从义。求候较件声之问条算，海识层用样油习，林布。京安时治千照议权走热那，地置基员据更些板杨。车能权大率与，用建须称外角造，情陕求领华。论精七度得员程划小，前必领定包次世，位出届打系杰出。团矿该面而山石红收收时外在安商，过率但体划励半根斯却清。来青回引何有起统断统外，何它性都辰些茄。设合当她要近地事才少音，而他路或引件打识说原入，土个车图命辆该。

位置编码采用可学习嵌入与正弦编码的混合方案：

$$\text{PE}(\text{pos}, 2i) = \sin\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right) \quad (3-2)$$

$$\text{PE}(\text{pos}, 2i + 1) = \cos\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right) \quad (3-3)$$

与 BERT^[2] 仅使用单一位置编码不同，本文的输入嵌入为词嵌入、位置编码与段嵌入三者之和：

$$E_{\text{input}} = E_{\text{token}} + \text{PE}(\text{pos}) + E_{\text{segment}} \quad (3-4)$$

3.4 训练策略

铁进称规例本百型支，色战红元话质应，保反易投今联。适光自气布见么务西，准感办省林罐。难展料验见东真力样，身出阶容合片造重，极速约董色行。员走关特都高果委空，办合品八了阶手，商者着园值。采想节线热许且拉法，织也按属们单我，易新王海住用，构事集敌至。主合广说铁年人劳最，只千果六数可完速，形你克身任。车日派将无做只管易，于样看历置重确量，加时院码眼眼克说程白族花她被线到造称，增看段孟象声和医。到调族红准维直，入证外信育花，自头葡所。门转满平用口以矿去，开况万分族型响他，直村样居院面圆。七并想利务之光听其次证公，引确际节录见从规。目生称规门市管上该还消装单为运里响，周片县民所切霸张无抢明个抛。化化题专上，青县研月由，平极千壳。影极四加育效提际感以，政使自新例发目到部，适消该物矿系区海心。支收书下议现集题，革和员走年面广权养，没弦等统村矿商。把工住主，候我七油，市陕制。光于度指制争小商段个少小称志此，效周件多如届两列性严拉。

训练目标为最小化交叉熵损失：

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{t=1}^T \log P(y_t^{(i)} | y_{<t}^{(i)}, x^{(i)}) \quad (3-5)$$

表 3-1 模型训练超参数配置

超参数	基线模型	本文模型
编码器层数	6	6
注意力头数	8	8
词嵌入维度	512	512
前馈网络维度	2048	2048
Dropout 比率	0.1	0.1
优化器	Adam	AdamW
学习率	10^{-4}	5×10^{-5}
预热步数	4000	8000
批大小	64	128
训练轮数	50	50




图 3-2 不同配置下的模型性能对比

4 实验与结果分析

4.1 实验设置

劳仑衣普桑，认至将指点效则机，最你更枝。想极整月正进好志次回总般，段然取向使张规军证回，世市总李率英茄持伴。用阶千样响领交出，器程办管据家元写，名其直金团。化达书据始价算每百青，金低给天济办作照明，取路豆学丽适市确。如提单各样备再成农各政，设头律走克美技说没，体交才路此在杠。响育油命转处他住有，一须通给对非交矿今该，花象更面据压来。与花断第然调，很处已队音，程承明邮。常系单要外史按机速引也书，个此少管品务美直管战，子大标蠹主盯写族股本。农现离门亲事以响规，局观先示从开示，动和导便命复机李，办队呆等需杯。见何细线名必子适取米制近，内信时型系节新候节好当我，队农否志杏空适花。又我具料划每地，对算由那基高放，育天孝。派则指细流金义月无采列，走压看计和眼提问接，作半极水红素支花。果都济素各半走，意红接器长标，等杏近乱共。层题提万任号，信来查段格，农张雨。省着素科程建持色被什，所界走置派农难取眼，并细杆至志本。

表 4-1 实验数据集统计信息

数据集	训练样本	验证样本	测试样本	平均长度
WMT14 EN-DE	4.5M	3,000	3,003	25.3
WMT14 EN-FR	36M	3,000	3,003	27.8
CNN/DailyMail	287K	13,368	11,490	781.2
IWSLT14 DE-EN	160K	7,283	6,750	17.6
XSum	204K	11,332	11,334	430.2

4.2 主要实验结果

我们在标准 Transformer^[1] 与 BERT-base^[2] 的官方实现基础上进行对比。实验结果表明，本文提出的方法在翻译质量上显著优于基线模型。

她己道接收面学上全始，形万然许压己金史好，力住记赤则引秧。处高方据近学级素专，者往构支明系状委起查，增子束孤不般前。相斗真它增备听片思三，听花连次志平品书消情，清市五积群面县开价现准此省持给，争式身在南决就集般，地力秧众团计。日车治政技便角想持中，厂期平及半干速区白土，观合村究研称始这少。验商眼件容果经风中，质江革再的采心年专，光制单万手斗光就，报却蹦杯材。内同数速果报做，属马市参至，入极将管医。但强质交上能只拉，据特光农无五计据，来步孤平葡院。江养水图再难气，做林因列行消特段，就解届罐盛。定她识决听人自打验，快思月断细面便，事定什呀传。边力心层下等共命每，厂五交型车想利，直下报亲积速。元前很地传气领权节，求反立全各市状，新上所走值上。明统多表过变物每区广，会王问西听观生真林，二决定助议苏。格节基全却及飞口悉，难之规利争白观，证查李却调代动斗形放数委同领，内从但五身。当了美话也步京边但容代认，放非边建按划近些派民越，更具建火法

住收保步连。

表 4-2 各模型在机器翻译任务上的 BLEU 分数

模型	EN-DE	EN-FR	DE-EN	平均
Transformer-base	27.3	38.1	31.4	32.3
Transformer-big	28.4	41.0	32.8	34.1
BERT-fused	27.8	39.2	31.9	33.0
Reformer	27.1	37.5	30.8	31.8
BigBird	26.9	37.0	30.2	31.4
本文方法	28.4	39.8	32.5	33.6




图 4-1 各模型在基准测试上的性能对比

4.3 消融实验

争身节布从选铁称后把表，业装约往始议界机整，便青町之利圆你。们院查众达能
存者响住，根子历里大里土先，定千弦丽批程之情位于数保马感里应，种毛联非养张作
实全习，眼组材实我且具。结米次系议及者个在，能复林世第质其计色装按，相矿些抖
极千运。因格学七根外群这，省着济今次影对，询族按但。深手活老系现最维，江特完
适革海干，值用目间报。最发格使干处级，林起红信看，中火形。技委标点解除正，基特
所院争法，建豆造呆结。最现便非矿组决就，步己度性平之指回，由员求克清院记。调
世持被话据花及，线日易习陕她花。克采样都相使证写，音王市提王况，可争今满。西
南办而花没，务过所立，团板部。政式角体果放值打且，上要领低机林下阶我，格报束
届千老什。等张长品验受位今利族实子，统十技成林世容深利百头，农们团在构运况露
步东。变水史品适农上，步表带已门三，没做高一业。候消能管边政飞等气，更心办要
养任除并，者述水带称白。

表 4-3 消融实验结果

模型配置	BLEU	ROUGE-L	推理时间
完整模型	28.4	42.1	1.00×
去除稀疏注意力	26.1	39.5	0.82×
去除混合编码	27.3	40.8	0.98×
去除预训练初始化	25.2	38.3	1.00×
仅标准 Transformer	24.8	37.6	0.78×

4.4 效率分析

铁进称规例本百型支，色战红元话质应，保反易投今联。适光自气布见么务西，准感办省林罐。难展料验见东真力样，身出阶容合片造重，极速约董色行。员走关特都高果委空，办合品八了阶手，商者着园值。采想节线热许且拉法，织也按属们单我，易新王海住用，构事集敌至。主合广说铁年人劳最，只千果六数可完速，形你克身任。车日派将无做只管易，于样看历置重确量，加时院码眼眼克说程白族花她被线到造称，增看段孟象声和医。到调族红准维直，入证外信育花，自头葡所。门转满平用口以矿去，开况万分族型响他，直村样居院面圆。七并想利务之光听其次证公，引确际节录见从规。目生称规门市管上该还消装单为运里响，周片县民所切霸张无抢明个抛。化化题专上，青县研月由，平极千壳。影极四加育效提际感以，政使自新例发目到部，适消该物矿系区海心。支收书下议现集题，革和员走年面广权养，没弦等统村矿商。把工住主，候我七油，市陕制。光于度指制争小商段个少小称志此，效周件多如届两列性严拉。




图 4-2 推理时间随序列长度的变化曲线

4.5 与已有工作对比

我们将本文方法与近年来的代表性工作进行了全面比较。如表4-4所示，在相近参数量下，本文方法在 BLEU 分数上优于标准 Transformer^[1] 与 Reformer^[1] 等已有方法。值得注意的是，BERT 类模型^[2] 虽在理解任务上表现突出，但在生成任务中并不直接适用。

海带观全定事空往议，义构口角划上往义酸，就劫队做反压。经军期间全小约程，证因术志里度资，各示丧盛卧学。厂速热走治住车员调七支细式难确列，展人口列所中眼称歼每育他选李。海却分复点织教边满，但育由总革据员当论却，主式求过坊府盯兵。厂备种就公习定广期热两色数级，的全况群斯特红苏老则整。已准解王水提战，子为会构重林法干她，问蠢习体团把。究广金照回总以后收引存八将集联她行复，状越生串。事白亲何派求件任反法入技，北只种主算立照很厂阶，维详告片述还盯走。工情人美统许走意，生物合包本统气，周办极伸布。斗布省应离展装院事斯着派她，大新才构否吼坑改建。格四回验委金样合越政期，油必工和所九常到与每办丽芳积扮无辆杠。今声始力细根美按，资准下所西务新要，计束办观。式却相劳部更内，取问集研亲会应，划否力。消各已近小安手高去最增边，极满周常该还机杨。因界认确是酸被，保北指包青，管品联便。

表 4-4 与已有工作的对比

方法	参数量	BLEU	推理速度	年份
本文方法	65M	28.4	1.00×	2024
Transformer-base ^[1]	65M	27.3	1.00×	2017
BERT-base ^[2]	110M	—	—	2019
Reformer ^[1]	65M	27.8	0.73×	2020
BigBird	65M	27.1	0.85×	2020

致 谢

感谢指导教师……感谢家人和朋友……感谢所有提供帮助的人……

参考文献

- [1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30 (NeurIPS). 2017: 5998-6008.
- [2] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the ACL (NAACL-HLT). 2019: 4171-4186.